• • Capítulo 6

Indexação (Continuação)

Continuação do Capítulo

- 1. Índices muito grandes na memória.
- 2. Acesso por múltiplas chaves.
- Recuperação por combinação de chaves secundárias.
- 4. Listas invertidas.
- 5. Índices seletivos.

• • Índices Muito Grandes na Memória

- O arquivo de índices não cabe na memória
 - ALTERNATIVA: acessar o arquivo de índices no disco
 - A busca binária requer várias operações de seek ao disco
 - o que aumenta o tempo gasto na pesquisa.
 - Obs: a busca binária no arquivo de índices não é substancialmente mais rápida do que no arquivo de dados.
 - Use algoritmos especializados que requerem número menor de seeks:
 - B-tree (Capítulo 8) e B+tree (Capítulo 9)
 - usa estruturas n\u00e3o lineares (\u00e1rvores) para organizar os \u00eandices.
 - Hash (Capítulo 10)
 - para os casos onde velocidade de acesso é a maior prioridade.

Péssima Idéia!!!

• • Índices Muito Grandes na Memória

- Vantagens do uso de índices, mesmo em memória secundária, sobre o uso do arquivo de dados ordenado por chave:
 - O uso de índices permite o uso de <u>pesquisa binária</u> para a obter acesso via chave num <u>arquivo de registros de tamanho variável.</u>
 - Se os registros do arquivo de índices forem substancialmente menores do que os do arquivo de dados, então <u>ordenação e</u> <u>manutenção dos índices serão menos custosas</u> do que se feitas no arquivo de dados.
 - Se existirem registros (arquivo de dados) excluídos numa LED, o uso de índices nos <u>permite rearranjar as chaves sem mover os</u> registros de dados.

• • Acesso por Múltiplas Chaves

- Buscas via chave primária são raras:
 - "Encontre o registro com a chave DG18807."
- Rotineiramente se faz acesso a registros por chave secundária:
 - "O que eu quero é a Sinfonia No. 9 do Beethoven."
- Podemos criar um catálogo para a coleção de gravações, por ex., consistindo de entradas para título do álbum, compositor e artista.



Acesso por Múltiplas Chaves

- O catálogo de uma biblioteca proporciona visões múltiplas da coleção da biblioteca, mesmo que exista apenas um único conjunto de livros organizados em uma única ordem.
- DA MESMA MANEIRA PODEMOS USAR ÍNDICES MÚLTIPLOS PARA PROPORCIONAR VISÕES MULTIPLAS DO ARQUIVO DE DADOS.
- Analogia à biblioteca: é muito raro buscar um livro pelo seu número de catálogo. Geralmente se busca por um assunto, título ou autor. Dado o título, autor ou assunto, se procura no catálogo a chave primária.

• • Acesso por Múltiplas Chaves

- Pode-se criar tantos índices quantas sejam as chaves de acesso.
- É possível implementar vários índices secundários.
- Cada índice dá uma visão diferente de um arquivo de dados.
 - é possível combinar essas visões:
 - fazendo buscas que sejam a união das respostas de índices secundários.
 - fazendo buscas que sejam a intersecção das respostas de índices secundários.

• • Acesso por Múltiplas Chaves

- Exemplo: um arquivo de índices (secundário) que relaciona Compositor com o LABEL ID.
 - Chave primária: LABEL ID
 - Chave secundária: Compositor (Beethoven)

Secondary	Primary
key	key
Beethoven	ANG3795
Beethoven	DG139201
Beethoven	DG18807
Beethoven	RCA2626
Corea	WAR23699
Dvorak	COL31809
Prokofiev	LON2312

A referência é para a chave primária, e não para o endereço do registro no arquivo (byte_offset). Isto significa que o arquivo de índices das chaves primárias deve ser consultado para encontrar o endereço do registro.

OBS: Existem diversas vantagens em não amarrar a chave secundária a um endereço específico.

Acesso por Múltiplas Chaves

Observação:

- No exemplo da biblioteca, uma vez que se obtém o número do catálogo, se pode ir direto às prateleiras pois os livros estão ordenados pelo número de catálogo (que é a chave primária).
- Já no nosso arquivo os registros estão na ordem de entrada. Por isso, após obter o LABEL ID deve-se ainda consultar o arquivo de índices das chaves primárias.

• • Acesso por Múltiplas Chaves

• INCLUSÃO DE REGISTROS:

- As entradas devem ser inseridas no arquivo de índices primário e no de índices secundário.
- Índice secundário:
 - Custo: similar ao de adicionar um registro ao arquivo de índices primário.

 Decresce muito se o arquivo de índices pode ser mantido e modificado em memória.
 - A chave é armazenada na forma canônica, e em registro de tamanho fixo.
 - Há uma natural duplicação de chaves secundárias.
 - Estas chaves estão agrupadas, e devem estar ordenadas pelo campo de referência (ou seja, pela chave primária).

Acesso por Múltiplas Chaves

• ELIMINAÇÃO DE REGISTROS:

- Requer remover todas as referências nos arquivos de índices primário e secundário.
 - implica em reorganizá-los: muito custoso se não cabem na memória.

Alternativa:

- Eliminar o registro do arquivo de dados e apenas a referência no arquivo de índices primário (<u>não modificar o arquivo de índice secundário</u>).
 - a busca pela chave secundária pode retornar um valor inválido quando retornar uma chave primária inexistente.
 - Como o índice secundário aponta para o índice primário a condição pode ser testada sem causar erro.

• • Acesso por Múltiplas Chaves

• ELIMINAÇÃO DE REGISTROS:

- Vantagem:
 - Se os índices secundários estão associados ao índice primário
 - os índices secundários não precisam ser atualizados.
- Custo:
 - Espaço ocupado por registros inválidos.
 - pode-se remover esses registros periodicamente.
 - Problema se o arquivo for muito volátil.
 - outra solução (por exemplo, uso de *B-Tree*) seria mais aconselhável, pois permite a eliminação ser ter que rearranjar muitos registros.

Obs: O registro excluído ainda ocupa espaço no arquivo de índices secundário. Caso muitas exclusões sejam feitas, pode-se periodicamente, limpar o arquivo de índices secundário.

• • Acesso por Múltiplas Chaves

ATUALIZAÇÃO DE REGISTROS:

- Se mudar a chave secundária:
 - Reordene o arquivo de índices secundário
- Se mudar a chave primária:
 - Reordene o arquivo de índices primário e atualize o arquivo de índices secundário (que contém a chave primária)
- Se mudar outro campo:
 - não afeta se o registro tem tamanho fixo.
 - não afeta se o campo alterado couber no atual espaço do registro de tamanho variável.
 - se o campo n\u00e3o couber no atual espa\u00e7o do registro vari\u00e1vel ent\u00e3o
 - trate como uma exclusão seguida de inclusão no arquivo de dados.
 - mude a PRR no arquivo de índices primário.



- Uma das mais importantes aplicações de chaves secundárias:
 - A utilização de duas ou mais chaves combinadas para recuperar um conjunto especial de registros de um arquivo de dados.
 - Encontre todas as gravações com compositor
 "BEETHOVEN" (chave secundária = compositor)
 - Encontre todas as gravações com o título "Violin Concerto"



Recuperação por Combinação de Chaves Secundárias

Exemplo:

Encontre todas as gravações com compositor "BEETHOVEN" e (and) título "Symphony No.9"

Matches	Matches	Matched
from	from title	list
composer	index	(logical
index		"and")
ANG3795	ANG3795	ANG3795
DG139201	COL31809	DG18807
DG18807	DG18807	
RCA2626		

Com o uso de índices secundários, este tipo de busca é simples e rápida, pois as operações lógicas são realizadas nos arquivos de índices, reduzindo assim os seeks.



Recuperação por Combinação de Chaves Secundárias

- Com esta facilidade de combinar listas ordenadas rapidamente, podemos recuperar:
 - Intersecções (Beethoven AND Symphony No. 9)
 - Uniões (Beethoven OR Prokofiev OR Symphony No. 9)

O arquivo de dados está na ordem de entrada (inserção temporal), e toda essa combinação pode ser feita sem precisar ordená-lo. A ordenação é feita somente nos pequenos arquivos de índices que geralmente podem ser mantidos em memória.

• • Problemas!!!

- A estrutura de índices secundários/primários possuem duas dificuldades:
 - 1. Requer reorganizar o arquivo de índices todas as vezes que é incluído um novo registro no arquivo.
 - Mesmo que seja para uma chave secundária já existente.
 - 2. Repetição das chaves secundárias
 - Perda de espaço; arquivos maiores sem necessidade.

Secondary	Primary
key	\mathbf{key}
Beethoven	ANG3795
Beethoven	DG139201
Beethoven	DG18807
Beethoven	RCA2626
Corea	WAR23699
Dvorak	COL31809
Prokofiev	LON2312

o 1a SOLUÇÃO:

- Fazer cada registro do arquivo de índice secundário, consistir da:
 - chave secundária + um array dos campos de referência para aquela chave

BEETHOVEN ANG3795 DG139201 DG18807 RCA2626

Problemas:

- O array terá um limite de tamanho e podemos ter mais registros para incluir.
- Podemos ter muitos espaços não utilizados em alguns arrays (fragmentação interna)

É uma lista de chaves primárias associada a uma chave secundária.

- 2a SOLUÇÃO: Listas Invertidas
 - Organizar o arquivo de índices secundário de maneira que cada registro contém a chave secundária e um ponteiro para uma lista encadeada de referências.

Secondary Key Index File LABEL ID List File

0	Beethoven	3
1	Corea	2
2	Dvorak	5
3	Prokofiev	7

0	LON2312	-1
1	RCA2626	-1
2	WAR23699	-1
3	ANG3795	6
4	DG18807	1
5	COL31809	-1
6	DG139201	4
7	ANG36193	0

o Vantagens:

- O arquivo de índices secundário só é rearranjado quando um novo compositor é adicionado ou o nome de um compositor é modificado.
 - Adicionar ou excluir gravações para um compositor somente afeta o arquivo contendo a lista LABEL ID.
 - Excluir todas as gravações para um compositor pode ser feito colocando "-1" no campo de referência do arquivo de índices secundário.

- Vantagens: (cont.)
 - Re-organizar o arquivo de índices secundário é mais rápido, pois ele está menor.
 - O arquivo da lista LABEL ID não precisa estar ordenado, pois está na ordem de entrada (inserção temporal).
 - Podemos facilmente reutilizar o espaço dos registros excluídos do arquivo contendo a lista LABEL ID, pois eles tem tamanho fixo.

o Desvantagens:

- Perda de "localidade"
 - Os labels das gravações que tem a mesma chave secundária não são contíguos no arquivo da lista LABEL ID (= muito seeking)
 - Para melhorar esta situação, uma alternativa seria manter o arquivo da lista LABEL ID em memória, ou se for muito grande, utilizar mecanismos de paginação, mantendo somente uma parte do arquivo em memória, conforme vão sendo necessárias.

 É possível colocar o arquivo de lista invertida no arquivo de chave principal criando campos para fazer a lista encadeada

			Registro do Ademar: administrativo
Registro	Ch. Principal	Endereço	
0	1002	4	Registro do Afonso: técnico
1	1002	3	Registro da Lara: comercial
2	1003	1	
3	1004	2	Registro do Carlos: administrativo
4	1005	0	Registro da Sônia: administrativo

Ex: arquivo de chave principal

Registro	Ch. Principal	Endereço (NRR)	Ch. Secun.	Próx.	Ant.
0	0001		Administrativo	3	7
1	0002		Técnico	4	4
2	0003		Comercial	5	5
3	1001	4	Administrativo	6	0
4	1002	3	Técnico	1	1
5	1003	2	Comercial	2	2
6	1004	1	Administrativo	7	3
7	1005	0	Administrativo	0	6

Exemplo de lista invertida juntamente com o arquivo de chave principal (inserida como cabeçalho)

Arquivos Multilistas

- Os arquivos de índice multilistas são a generalização das listas invertidas. Exemplo:
 - Consideremos um arquivo com dados de alunos
 - Chave principal (CP) a matrícula
 - Chaves secundárias (CS): o estado e IRA
 - Campos incrementais (CI) não são chave principal ou secundária (não podem ser utilizados em busca) porém são frequentemente acessados e incluidos no arq. Índice (ex: nome)
 - Outras informações adicionais (ex: sobrenome, endereço, etc.) são gravados somente no arq. principal.

Arquivos Multilistas

 Geramos uma lista com todas as informações que farão parte do arquivo INDEX ordenado pela chave principal

СР	CI	CS1	CS2
1001111	João	MG	4
1002222	José	SP	5
1003333	Maria	RJ	5
1004444	Gérson	MG	5
1100000	Sandra	SP	4
1101111	Miguel	MG	4
1102222	Ana	SP	4

 Atribuimos a informação de endereço (NRR ou PRR) gerando a lista "A"

СР	ED	CI	CS1	CS2
1001111	1	João	MG	4
1002222	2	José	SP	5
1003333	3	Maria	RJ	5
1004444	4	Gérson	MG	5
1100000	5	Sandra	SP	4
1101111	6	Miguel	MG	4
1102222	7	Ana	SP	4

 Ordenamos as triplas por chave secundária e inserimos os ponteiros

CS1	ED	CP	P1
MG	1	1001111	4
MG	4	1004444	6
MG	6	1101111	-1
RJ	3	1003333	-1
SP	2	1002222	5
SP	5	1100000	7
SP	7	1102222	-1

CS2	ED	CP	P1
4	1	1001111	5
4	5	1102222	6
4	6	1101111	7
4	7	1102222	-1
5	2	1002222	3
5	3	1003333	4
5	4	1001111	-1

 Geramos arquivo "index" de lista invertidas para cada índice secundário (podendo ou não incluir quantidade de registros de cada valor)

CS1	ED	Quantid.
MG	1	3
RJ	3	1
SP	2	3

CS2	ED	Quantid.
4	1	4
5	2	3

Reordenamos as listas anteriores pela chave principal

CS1	ED	CP	P1
MG	1	1001111	4
SP	2	1002222	5
RJ	3	1003333	-1
MG	4	1004444	6
SP	5	1100000	7
MG	6	1101111	-1
SP	7	1102222	-1

CS2	ED	CP	P1
4	1	1001111	5
5	2	1002222	3
5	3	1003333	4
5	4	1004444	-1
4	5	1100000	6
4	6	1101111	7
4	7	1102222	-1

 Incluir os ponteiros na lista "A". A nova lista será o arquivo "index" de chave principal

СР	ED	CI	CS1	CS2	P1	P2
1001111	1	João	MG	4	4	5
1002222	2	José	SP	5	5	3
1003333	3	Maria	RJ	5	-1	4
1004444	4	Gérson	MG	5	6	-1
1100000	5	Sandra	SP	4	7	6
1101111	6	Miguel	MG	4	-1	7
1102222	7	Ana	SP	4	-1	-1

• • Indices Seletivos

- Podemos construir índices seletivos, tais como:
 - "Gravações lançadas antes de 1970."
 - "Gravações lançadas desde 1970."
 - Também podemos utilizar operações booleanas:
 - "Recupere todas as gravações de Beethoven desde 1970"
 - Verifiquem a metodologia de indexação do iTunes(Apple) x Windows Media Player!